

https://lms.hse.ru/?apview&h_id=14AB5C7F-B9BF-4E1E-9921-E4AAC6B70562



ФИО:	Насыхова Анастасия Артемовна
Руководитель:	Кузнецов Сергей Олегович, профессор
Факультет:	факультет компьютерных наук
Кафедра/Группа:	МНКДН241
Уровень обучения:	Магистратура
Образовательная программа:	Науки о данных
Адрес электронной почты:	nasykhova@mail.ru
Контактный телефон:	+7(917)880-55-89
Название (тема) по-русски:	Разработка семантической иерархии для лингвистической разметки на основе кластеризации в языковых моделях
Название (тема) по-английски:	Development of a Semantic Hierarchy for Linguistic Markup Based on Clustering in Language Models
Язык работы:	Русский
Процент заимствования:	0
Дата загрузки работы:	22-05-2026 22:11:59

Аннотация:

Данная работа посвящена разработке и экспериментальной верификации методологии автоматического построения интерпретируемой семантической онтологии на основе латентных представлений больших языковых моделей (LLM). Актуальность исследования обусловлена необходимостью создания масштабируемых и адаптивных ресурсов знаний, способных дополнять или уточнять экспертные таксономии, такие как корпус CoBaLD.

В ходе исследования проведён систематический анализ архитектур векторных представлений, алгоритмов кластеризации и методов трансформации пространства. Эксперименты выполнены на выборке из 288,513 лексических единиц корпуса CoBaLD, размеченных по 565 семантическим классам.

Ключевые результаты:

1. Установлено, что эмбединги последнего слоя трансформеров избыточно специализированы под задачу генерации и непригодны для прямой онтологической кластеризации.
2. Промежуточные слои (0.4N) содержат более абстрактные представления, однако требуют дополнительной реструктуризации пространства для выделения устойчивых семантических групп.
3. Слабосупервизированное контрастивное обучение с разделением hard negatives позволяет достичь согласованности с экспертной разметкой, подтверждая гипотезу о возможности извлечения топологической семантики из дистрибутивных представлений.

Ключевые слова: большие языковые модели (LLM), векторные представления, семантическая онтология, кластеризация эмбедингов, контрастивное обучение, CoBaLD, XAI.

Аннотация (англ.):

This thesis is devoted to the development and experimental verification of a

methodology for the automatic construction of an interpretable semantic ontology based on latent representations of large language models (LLMs). The relevance of the research is driven by the need for scalable and adaptive knowledge resources capable of complementing or refining expert taxonomies such as the CoBaLD corpus.

The study conducts a systematic analysis of vector representation architectures, clustering algorithms (K-Means, DBSCAN, HDBSCAN, Leiden), and space transformation methods. Experiments were performed on a sample of 288,513 lexical units from the CoBaLD corpus, annotated across 565 semantic classes.

Key findings:

1. Final-layer transformer embeddings are excessively specialized for generative tasks and unsuitable for direct ontological clustering.
2. Intermediate layers (0.4N) contain more abstract representations but require additional space restructuring to extract stable semantic groups.
3. Weakly-supervised contrastive learning with hard negative mining achieves alignment with expert annotations, confirming the hypothesis that topological semantics can be extracted from distributional representations.

Keywords: large language models (LLMs), vector embeddings, semantic ontology, embedding clustering, contrastive learning, CoBaLD, XAI.

Я подтверждаю, что выпускная квалификационная работа выполнена мною лично и:

1. не воспроизводит мою собственную работу, выполненную ранее, без ссылки на нее в качестве источника;
2. не воспроизводит работу, выполненную другими авторами, без указания ссылки на источник учебной или научной литературы, статьи, вебсайты, выполненные задания или конспекты других студентов;
3. не предоставлялась ранее на соискание ступени более высокого уровня;
4. содержит правильно использованные цитаты и ссылки;
5. включает полный библиографический список ссылок и источников, которые были использованы при написании работы.

Мне известно, что нарушение правил цитирования и указания ссылок рассматривается как обман или попытка ввести в заблуждение, а также квалифицируется как нарушение Правил внутреннего распорядка НИУ ВШЭ.

Я ~~разрешаю~~ / отказываюсь по причине (нужное оставить)

(указать причину отказа в публикации)

НИУ ВШЭ безвозмездно воспроизводит и размещать (доводить до всеобщего сведения) в полном объеме написанную мною в рамках выполнения образовательной программы выпускную квалификационную работу (бакалавра/дипломную работу/магистерскую диссертацию) с указанием моего авторства и даты выполнения работы, а также данных о научном руководителе моей работы, в сети Интернет на корпоративном портале (сайте) НИУ ВШЭ, расположенном по адресу www.hse.ru, таким образом, чтобы любой пользователь данного портала мог получить доступ к полному тексту выпускной квалификационной работы из любого места и в любое время по собственному выбору.

Дата:

23-05-2026

Подпись:

